

MapReduce job mit Java in Eclipse

1. Einleitung

Eclipse kann (unter Nutzung der „Eclipse public license“) frei von www.eclipse.org für alle gängigen Plattformen heruntergeladen werden. Anbei ein paar Screenshots für Installation unter Linux. Es kann die aktuellste Version verwendet werden.

Um gradle als Buildsystem zu verwenden, ist es am einfachsten, das plugin für IntelliJ zu installieren. Für die Verwendung auf der Kommandozeile kann es nötig sein, den Installationspfad des gradle-plugins in den Pfad unter „Umgebungsvariablen“ aufzunehmen oder Gradle direkt von <https://gradle.org/releases/> herunterzuladen und zu installieren.

2. Generell



Folgende 2 Varianten bieten sich an, das Projekt zu bauen:



1. Mit Hilfe eines externen build systems (vorbereitetes build.gradle File)
2. Mit Hilfe von Eclipse selbst als Build-System (erfordert etwas mehr Vorbereitung, ist aber vielleicht besser zu verstehen)

Im Folgenden wird bei Abweichungen zwischen den Varianten stets die Notation @gradle bzw. @eclipse verwendet.

3. Installation

The screenshot shows a web browser window with the URL <https://www.eclipse.org/downloads/>. The page features the Eclipse Foundation logo at the top left. Navigation links include Projects, Working Groups, Members, More, and a search bar. A prominent orange banner on the left side reads "Download Eclipse Technology that is right for you". To the right of the banner is a sponsored advertisement for Fraunhofer FOKUS, featuring their logo and the tagline "We connect everything". Below the banner, there's a section for "Tool Platforms" with a callout pointing to the Eclipse IDE download. The callout text says: "The Eclipse Installer 2021-09 R now includes a JRE for macOS, Windows and Linux." It includes a download link for "Download x86_64". Another section for "Eclipse Che" is also visible, describing it as a developer workspace server and cloud IDE.





eclipseinstaller

by Oomph

★ DONATE



type filter text



Eclipse IDE for Java Developers

The essential tools for any Java developer, including a Java IDE, a Git client, XML Editor, Maven and Gradle integration



Eclipse IDE for Enterprise Java and Web Developers

Tools for developers working with Java and Web applications, including a Java IDE, tools for JavaScript, TypeScript, JavaServer...



Eclipse IDE for C/C++ Developers

An IDE for C/C++ developers.



Eclipse IDE for Embedded C/C++ Developers

An IDE for Embedded C/C++ developers. It includes managed cross build plug-ins (Arm and RISC-V) and debug plug-ins (SEGGER...)

Als Java Version muss eine Version >= 11 installiert werden.

[DONATE](#)

eclipseinstaller

by Oomph



Eclipse IDE for Enterprise Java and Web Developers

[details](#)

Tools for developers working with Java and Web applications, including a Java IDE, tools for JavaScript, TypeScript, JavaServer Pages and Faces, Yaml, Markdown, Web Services, JPA and Data Tools, Maven and Gradle, Git, and more.

Java 11+ VM

/usr/lib/jvm/java-1.11.0-openjdk-amd64




Installation Folder

/home/hduser/eclipse/jee-2021-092



- create start menu entry
- create desktop shortcut

 [INSTALL](#) [BACK](#)



4. Project anlegen
@eclipse:

New Project



Select a wizard

Create a Java project



Wizards:

type filter text

Java Project

Java Project from Existing Ant Buildfile

Plug-in Project

General

Eclipse Modeling Framework

EJB

Gradle

Java




< Back

Next >



Cancel



Finish


Wenn eine Java-Version > 11 verwendet wird, dann muss in Kompatibilität Version 11 gewählt werden.




Achtung: in neueren Eclipse-Versionen muss man die einzelnen Libraries unter "Classpath" dazuhängen, davor sind die Buttons ausgegraut.










Wichtig: Im folgenden Fenster nicht "Finish", sondern "Next" klicken, damit die weiteren Detaileingaben zu Manifest und v.a. Einsprungspunkt gesetzt werden können.



JAR Export

JAR Manifest Specification

Customize the manifest file for the JAR file.



Specify the manifest:

Generate the manifest file

- Save the manifest in the workspace
- Use the saved manifest in the generated JAR description file

Manifest file:

[Browse...](#)

Use existing manifest from workspace

Manifest file:

[Browse...](#)

Seal contents:

Seal the JAR

[Details...](#)

Seal some packages

Nothing sealed

[Details...](#)

Select the class of the application entry point:

Main class:

[Browse...](#)




[< Back](#)


[Next >](#)

[Cancel](#)

[Finish](#)



Das Hakerl bei "Export class file with compile errors" sollte man entfernen, sonst gibt's erst Fehler zur Laufzeit.



@gradle:

1. Projekt als „Existing Gradle Project“ importieren

1. Menü **File → Import....**
2. Im Dialog:
 - Kategorie **Gradle** aufklappen.
 - Eintrag **Existing Gradle Project** wählen.
 - **Next.**

3. Bei „Project root directory“ den Ordner auswählen, in dem die `build.gradle` für das WordCount-Projekt liegt.
4. **Next** → Eclipse liest jetzt das Gradle-Projekt ein.
5. **Finish**.

Ergebnis:

- Im „Package Explorer“: Das Projekt sollte bereits die richtige Ordnerstruktur haben (`.java`-Dateien unter `src/main/java/...`).
 - Wenn dies nicht der Fall ist, dann einfach einen Source Folder anlegen und die Dateien dort hin verschieben: Rechtsklick auf Projekt → **New** → **Source Folder** → Name: `src/main/java`.
 - Damit die Einstellungen übernommen werden: Rechtsklick auf das Projekt → **Gradle** → **Refresh Gradle Project**.
- Die Hadoop-Bibliotheken werden automatisch über die `dependencies` in der `build.gradle` übernommen – man muss sie nicht manuell als External JARs hinzufügen.

2. Projekt über den Gradle Tasks View bauen und Jar erstellen

1. Menü **Window** → **Show View** → **Other...**
2. Kategorie **Gradle** → **Gradle Tasks**.
3. In der „Gradle Tasks“-Ansicht das Projekt auswählen.
4. Unter der Gruppe **build** entweder **build** oder **jar** wählen.

Standardmäßig erzeugt Gradle das Jar unter dem Pfad `build/libs/<projektname>-<version>.jar`. In diesem Fall unter `build/libs/Hadoopwordcount-1.0.jar`

6. Prüfung des erstellten Artifacts und Kopieren auf Zielplattform

Je nach verwendetem Buildsystem und deren Settings findet man das generierte Jar-File unter z.B. `out/artifacts` oder `build/libs` und beinhaltet der Dateiname eine Versionsnr. oder nicht.

Das `build.gradle` beinhaltet einen „deploy“ Task, dieser funktioniert jedoch nur bei Passwort-based login bzw. müsste man die Credentials und Hostnamen ändern.

Daher am besten händisch die Datei manuell kopieren als user „student“ und dann die Datei dem hduser „schenken“:

```
scp -I <PrivateKeyFile> Hadoopwordcount-1.0.jar
student@<hostname>:/tmp/Hadoopwordcount-1.0.jar
ssh student@<hostname>
sudo chown hduser:hadoop /tmp/Hadoopwordcount-1.0.jar
su - hduser
mv /tmp/Hadoopwordcount-1.0.jar ~/Hadoopwordcount.jar
```

7. Test des generierten jar-Files

Hadoop starten und Test aufrufen mit dem zuvor generierten und auf die Zielplattform kopierten Jar-File.

Job ausführen

- 1.) Input Ordner und Beispiel Textdatei im hdfs anlegen
- 2.) Job ausführen (Vorsicht Pfade sind ggf. anzupassen!)

```

su - hduser
start-dfs.sh
start-yarn.sh
hdfs dfs -mkdir /input
hdfs dfs -mkdir /output
hdfs dfs -put ~/BigData/data/Bibel.txt /input/
OutputDir=/output/Bibel
# folgendes für jeden Versuch neu ausführen
hdfs dfs -rm -R $OutputDir
hadoop jar Hadoopwordcount.jar /input/Bibel.txt $OutputDir

```

Bei Problemen (vor allem wenn Meldung „main class not found“) die Jar-Datei überprüfen ("jar -tvf" funktioniert meines Wissens nur unter Linux), sie muss zumindest folgende 4 Dateien beinhalten:

```

jar -tvf Hadoopwordcount.jar | awk '{ print $8 }'
META-INF/MANIFEST.MF
at/fhj/MapClass.class
at/fhj/ReduceClass.class
at/fhj/WordCount.class

```

Der Inhalt der Datei MANIFEST.MF sollte wie folgt sein (optional stehen dahinter noch ClassPaths):

```

jar -xf Hadoopwordcount.jar META-INF/MANIFEST.MF
cat META-INF/MANIFEST.MF
Manifest-Version: 1.0
Main-Class: at.fhj.WordCount

```

Erwarteter Output nach erfolgreichem MapReduce Job wie folgt:

```

hduser@osboxes: ~/Desktop
Reduce input groups=56030
Reduce shuffle bytes=9199249
Reduce input records=781853
Reduce output records=56030
Spilled Records=1563706
Shuffled Maps =1
Failed Shuffles=0
Merged Map outputs=1
GC time elapsed (ms)=55
Total committed heap usage (bytes)=706740224
Shuffle Errors
BAD_ID=0
CONNECTION=0
IO_ERROR=0
WRONG_LENGTH=0
WRONG_MAP=0
WRONG_REDUCE=0
File Input Format Counters
Bytes Read=4579278
File Output Format Counters
Bytes Written=614705
Job was successful
hduser@osboxes:~/Desktop$ 

```

Im angegebenen Output-Verzeichnis befinden sich dann 2 Dateien, eine leere Datei "_SUCCESS" und eine Datei mit dem Ergebnis des Jobs (wäre der Output größer als konfigurierte Blockgröße würde es weitere Dateien part-r-00001 usw. geben).

The screenshot shows the Hadoop File Explorer interface at localhost:9870/explorer.html#/output/bibel. The top navigation bar includes links for Hadoop, Overview, Datanodes, Datanode Volume Failures, Snapshot, Startup Progress, and Utilities.

The main area displays a 'Browse Directory' view for the path `/output/bibel`. It shows two files: `_SUCCESS` (0 B, Nov 04 15:18) and `part-r-00000` (363.59 KB, Nov 04 15:18). A search bar and various file operations buttons are available.

A modal window for `File information - part-r-00000` is open. It contains the following details:

- Download
- Head the file (first 32K)
- Tail the file (last 32K)** (highlighted with a red box)
- Block information -- Block 0
- Block ID: 1073741956
- Block Pool ID: BP-109114966-127.0.1.1-1698821495461
- Generation Stamp: 1138
- Size: 372320
- Availability:
 - UbuntuBigData

The 'File contents' section shows the following text:

```
mme      1
verstummen 1
verstummt   2
verstummte  1
```

Das "Tail the file" funktioniert üblicherweise nicht über die GUI, daher besser über Kommandozeile:

```
hdfs dfs -tail /output/Bibel/part-r-00000
hdfs dfs -head /output/Bibel/part-r-00000
```

Auf der Webseite von Yarn sieht man die erledigten Jobs ebenfalls (zu sehen nur im Fall, wenn `mapreduce.framework.name` auf „yarn“ und nicht „local“ eingestellt wurde):

← → ⌂ ⌂ Nicht sicher namenode:8088/cluster/apps/FINISHED

The screenshot shows the Hadoop Cluster Metrics interface. The URL in the address bar is "namenode:8088/cluster/apps/FINISHED". The page title is "hadoop". On the left, there's a sidebar with "Cluster" expanded, showing "About", "Nodes", "Node Labels", and "Applications" with sub-options: NEW, NEW_SAVING, SUBMITTED, ACCEPTED, RUNNING, FINISHED, FAILED, KILLED, and Scheduler. Below that is a "Tools" section. The main content area has three tabs: "Cluster Metrics", "Cluster Nodes Metrics", and "Scheduler Metrics". "Cluster Metrics" shows 1 App Submitted, 0 Apps Pending, 0 Apps Running, 1 Apps Completed, and 0 Containers Running. "Cluster Nodes Metrics" shows 3 Active Nodes, 0 Decommissioning Nodes, and 0 Decommissioned. "Scheduler Metrics" shows Capacity Scheduler with Scheduling Resource Type [memory-mb (unit=Mi), vcores] and Minimum Allocation <memory:1024, vCores:1>, Maximum Allocation <memory:8192, vCores:4>. A table titled "Scheduler Metrics" lists one application entry:

ID	User	Name	Application Type	Queue	Application Priority	StartTime	LaunchTime
application_1763115893210_0003	hduser	my word count	MAPREDUCE	root.default	0	Fri Nov 14 11:31:47 +0100 2025	Fri Nov 14 11:31:49 +0100 2025

Showing 1 to 1 of 1 entries

Wichtig: wenn der Job erneut gestartet werden soll, muss zuvor das Output-Verzeichnis gelöscht werden (sowohl wenn man Output ins lokale Dateisystem als auch wenn man dies in hdfs schreibt)!