# MapReduce job mit Java in IntelliJ IDE

IntelliJ community Edition (lizenzfrei) von
https://www.jetbrains.com/idea/download/?section=windows herunterladen

Nach Installation ein neues Java-Projekt anlegen, passende JDK-Version auswählen.

Am besten gradle oder maven als Buildsystem auswählen, damit dies leichter wiederverwendbar ist.

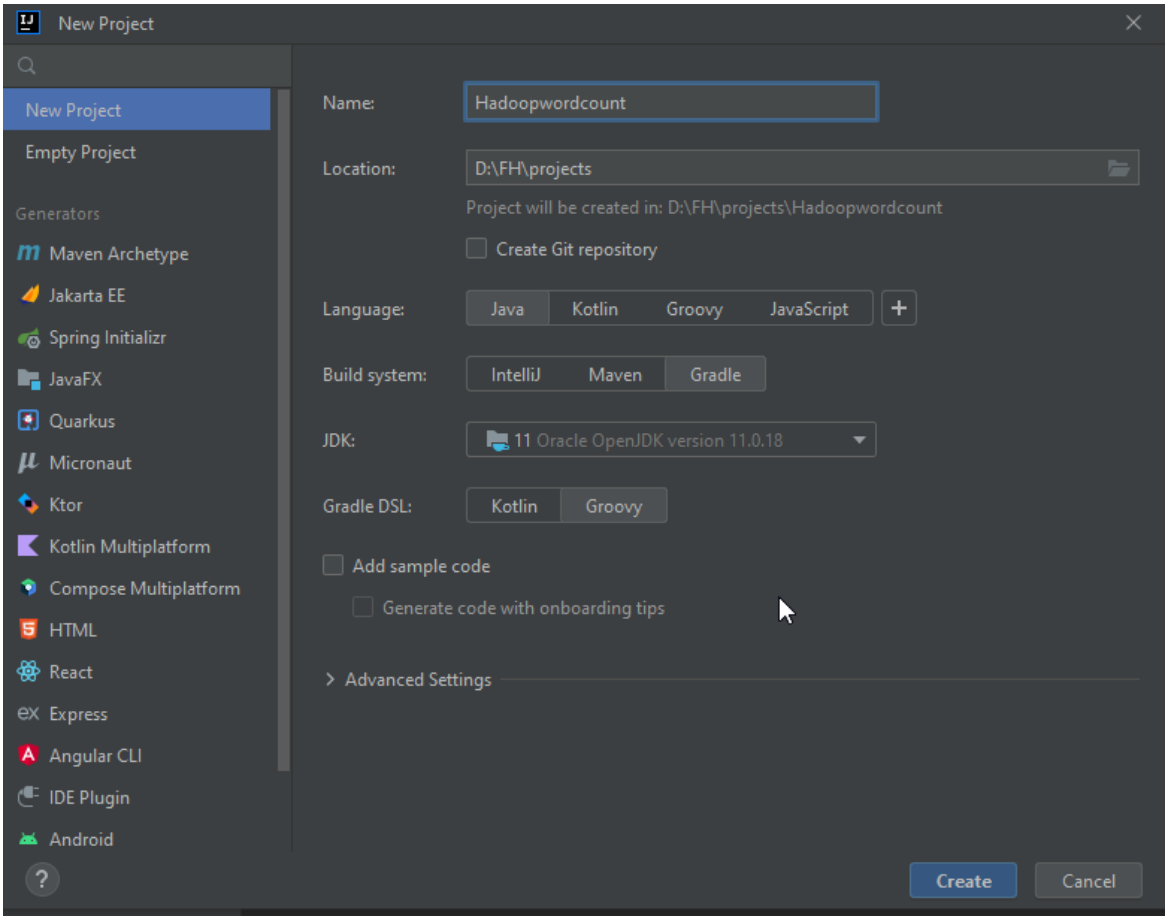


das automatisch generierte build.gradle sollte wie folgt aussehen, nur die "group" ist zu ändern.

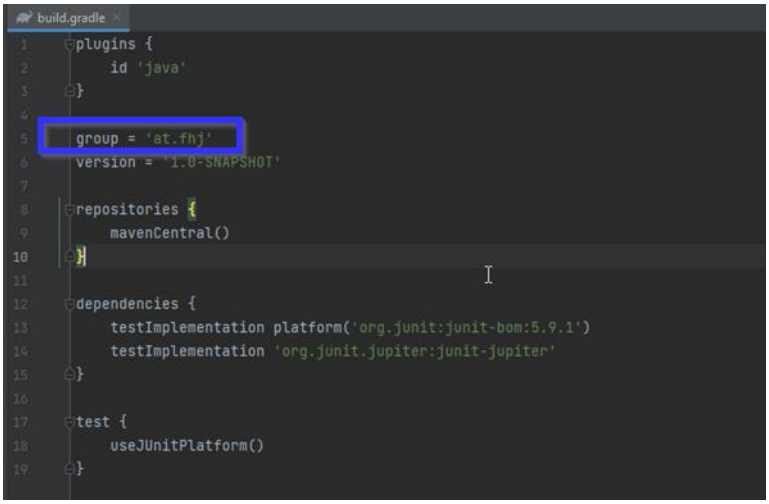

Besser jedoch das build.gradle aus dem github-Repo (https://github.com/Woberegger/BigData/tree/main/src/wordcount) abholen, dort sind auch die dependencies schon eingetragen – danach folgendes ausführen, damit das build-File neu geladen wird – es sollten darauf hin etliche Jar-Files aus dem zentralen Repo im Internet runtergeladen werden:

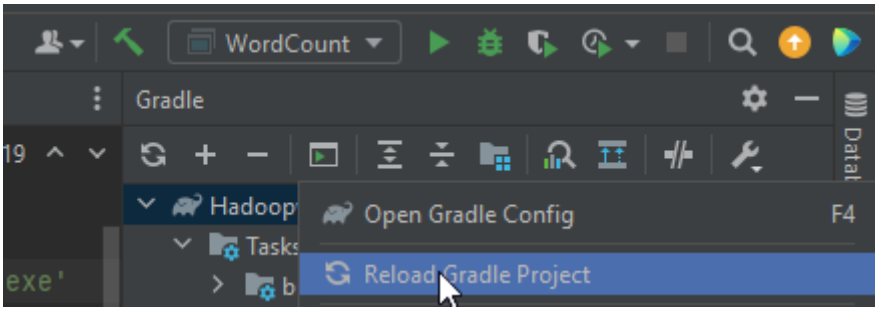


ein neues Package at.fhj anlegen, damit die Struktur der Defaultstruktur enspricht.

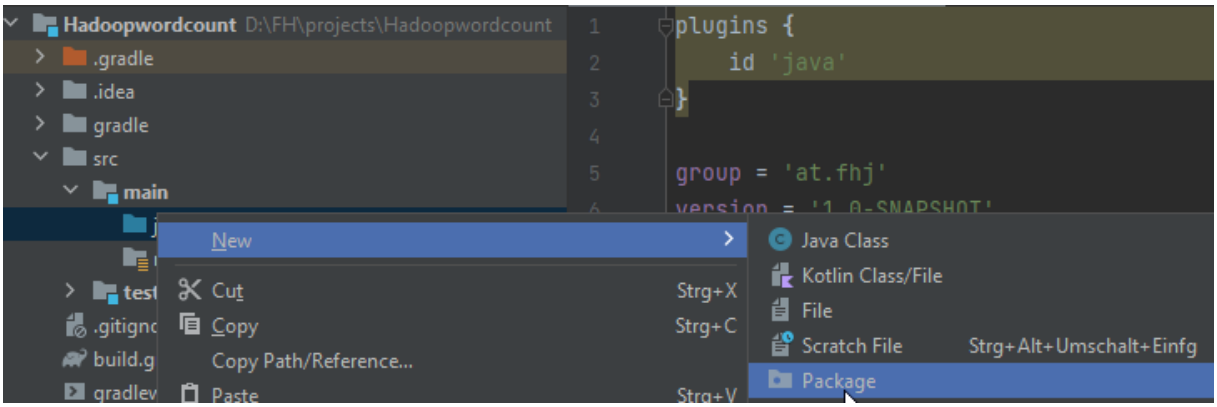


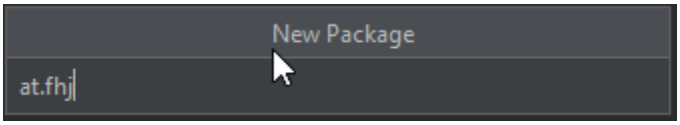


Dort die 3 Sourcefiles ablegen (am einfachsten durch Kopieren von https://github.com/Woberegger/BigData/tree/main/src/wordcount in das zuvor angelegte Package-Directory)

Projektstruktur anpassen:

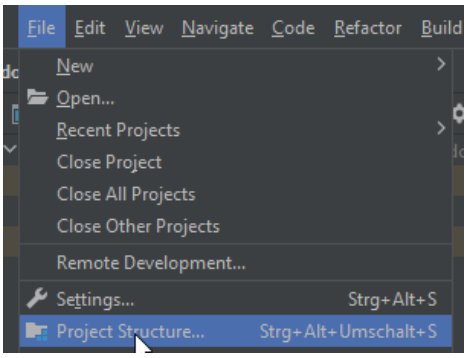


Damit die Dependencies aufgelöst werden, gibt es mehrere Möglichkeiten:

a) MavenCentral repo verwenden (siehe build.gradle)

b) Jar-Dateien zum Projekt hinzufügen (die Dateien entweder aus der E-Learning-Plattform oder noch besser vom installierten hadoop in der virtuellen Maschine – ACHTUNG: Versionen müssen zusammenpassen, es ist aber möglich, mit niedrigerer Version zu bauen, als die Version in der virtuellen Maschine):

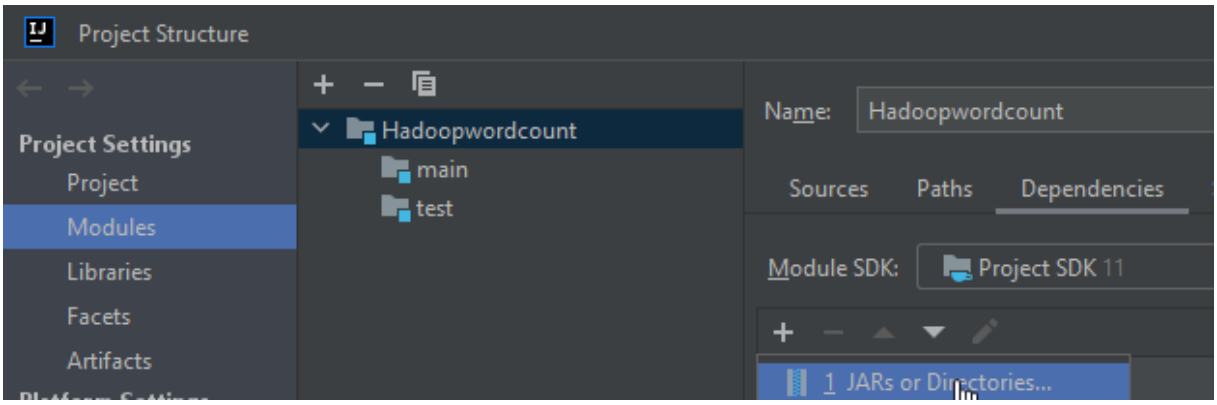


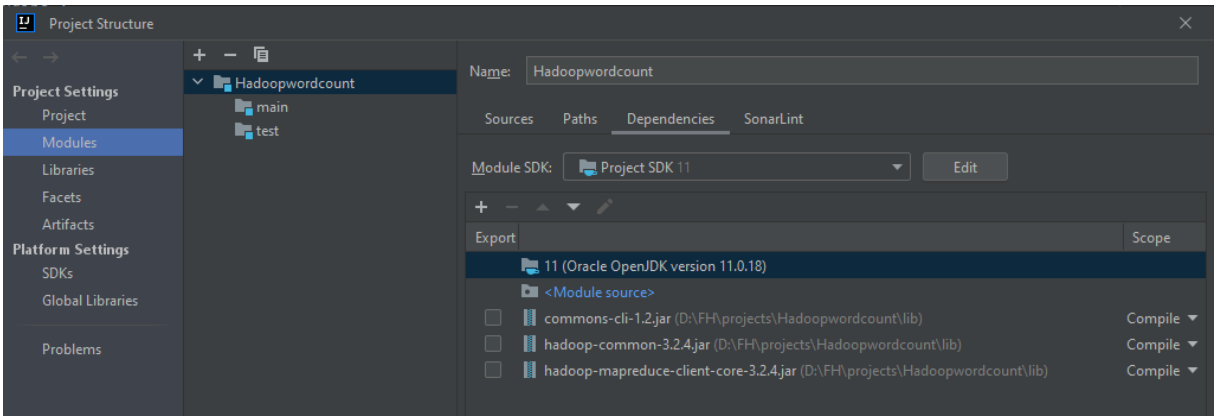


Projektstruktur, nachdem die Sourcedateien dort abgelegt wurden

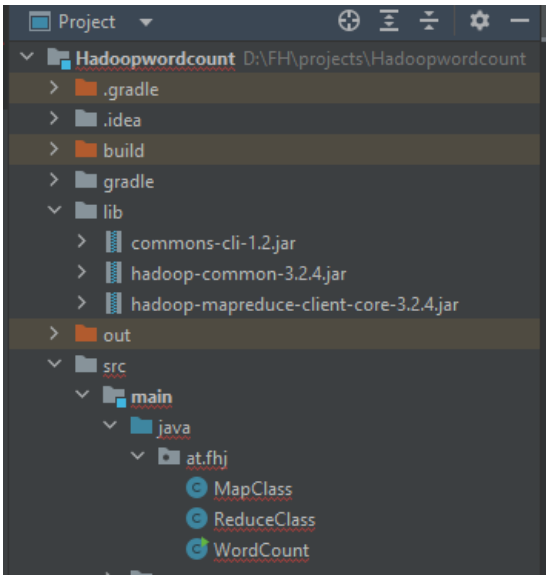


Projekt bauen, d.h. kompilieren

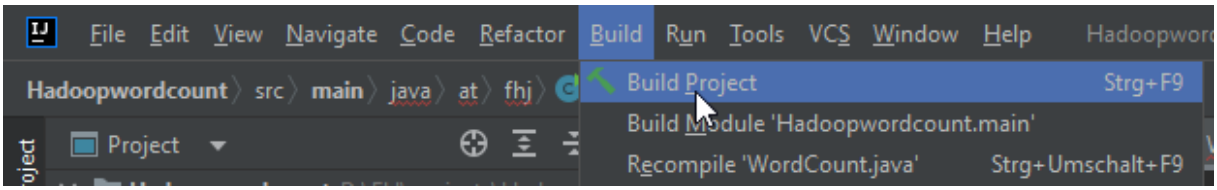


Ausführen oder Debuggen direkt bei den jeweiligen Methoden (müsste man remote debuggen auf der Zielplattform verwenden, wo DFS installiert ist), d.h. dieser Schritt ist im Normalfall zu überspringen.

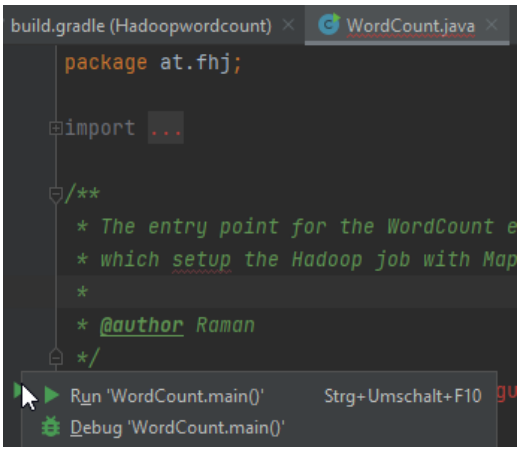


Artifakt anlegen, d.h. über "Project structure" das Erstellen des jar-File konfigurieren und dem Jar-File mitteilen, wo der Einsprungspunkt, d.h. die Main-Klasse, zu finden ist.

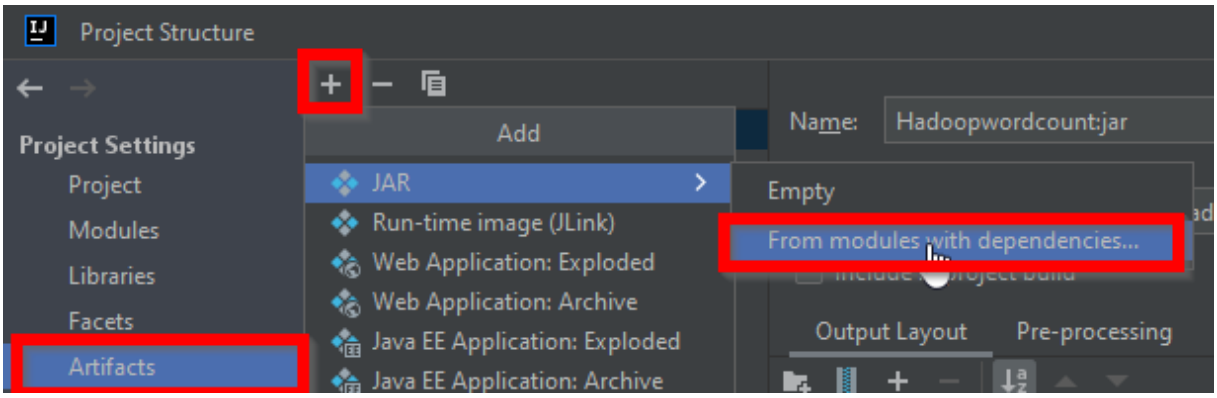

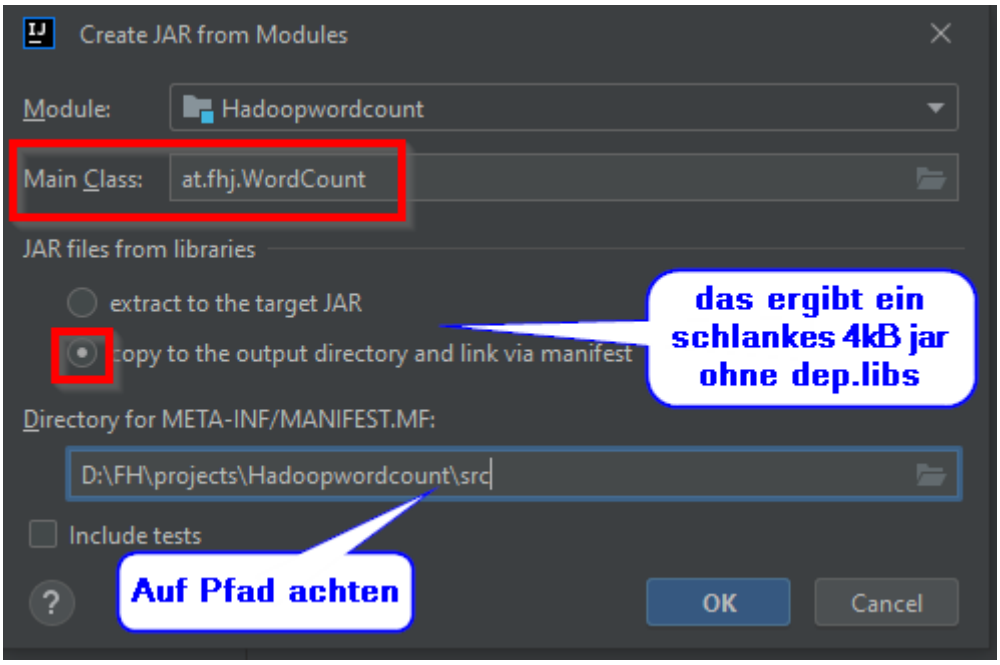


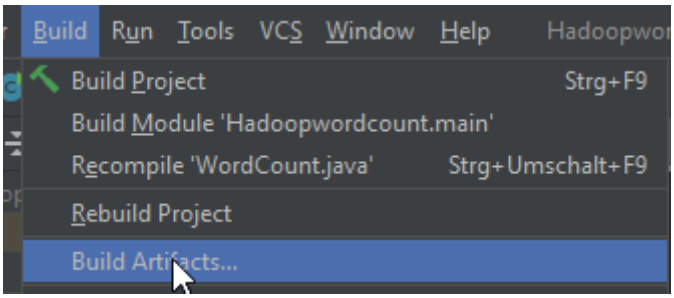


Je nach verwendetem Buildsystem und deren Settings findet man das generierte Jar-File unter z.B. out/artifacts oder build/libs und beinhaltet der Dateiname eine Versionsnr. oder nicht.

Falls zuvor schon eine Version dort gebildet wurde, die nicht funktioniert (weil z.B. fehlende Dependencies), diese besser über "Clean" zuerst löschen.

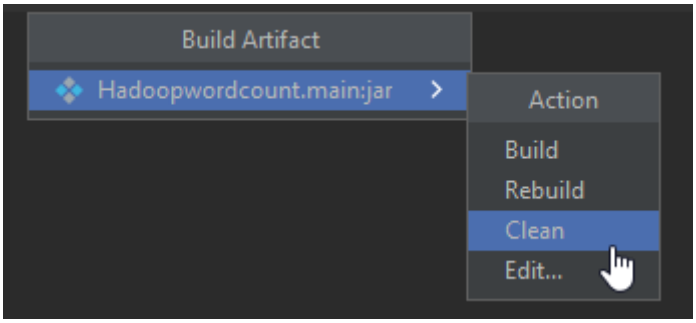


Falls auf dem lokalen System eine höhere Java-Version ("java –version") installiert ist als in der virtuellen Maschine, dann sollte folgende Einstellung ins build.gradle übernommen werden (optional Version VERSION_1_8 verwenden, falls dies verlangt wird – kann gerade bei MacOS nötig sein).

```
java {
   sourceCompatibility = JavaVersion.VERSION_11
   targetCompatibility = JavaVersion.VERSION_11
}
```

Wenn man gradle verwendet mit einem reinkopierten build.gradle, sollte man Folgendes ausführen:

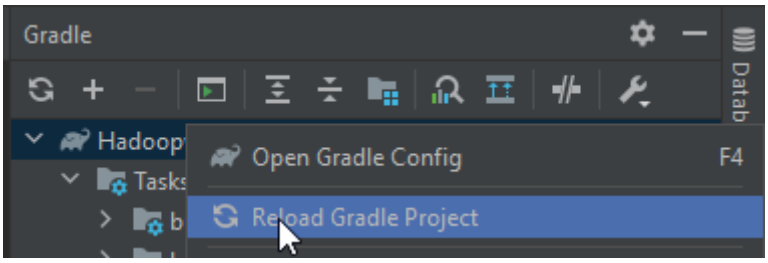


Optional auf Kommandozeile:

```
gradle task Jar
```

Hadoop starten und Test aufrufen mit dem zuvor generierten und auf die Zielplattform kopierten Jar-File.

Job ausführen

1.) Input Ordner und Beispiel Textdatei im hdfs anlegen
2.) Job ausführen (Vorsicht Pfade sind ggf. anzupassen!)

```
su - hduser
start-dfs.sh
start-yarn.sh
hdfs dfs -mkdir /input
hdfs dfs -mkdir /output
hdfs dfs -put ~/BigData/data/Bibel.txt /input/
OutputDir=/output/Bibel
# folgendes für jeden Versuch neu ausführen
hdfs dfs -rm -R $OutputDir
hadoop jar HadoopWordCount.jar /input/Bibel.txt $OutputDir
```

Bei Problemen die Jar-Datei überprüfen ("jar -tvf" funktioniert meines Wissens nur unter Linux), sie muss zumindest folgende Dateien beinhalten:

```
jar -tvf HadoopWordCount.jar | awk '{ print $8 }'
META-INF/MANIFEST.MF
at/fhj/MapClass.class
at/fhj/ReduceClass.class
at/fhj/WordCount.class
```

Der Inhalt der Datei MANIFEST.MF sollte wie folgt sein:

```
jar -xf minimal.jar META-INF/MANIFEST.MF
cat META-INF/MANIFEST.MF
Manifest-Version: 1.0
Main-Class: at.fhj.WordCount
```

Erwarteter Output nach erfolgreichem MapReduce Job wie folgt:

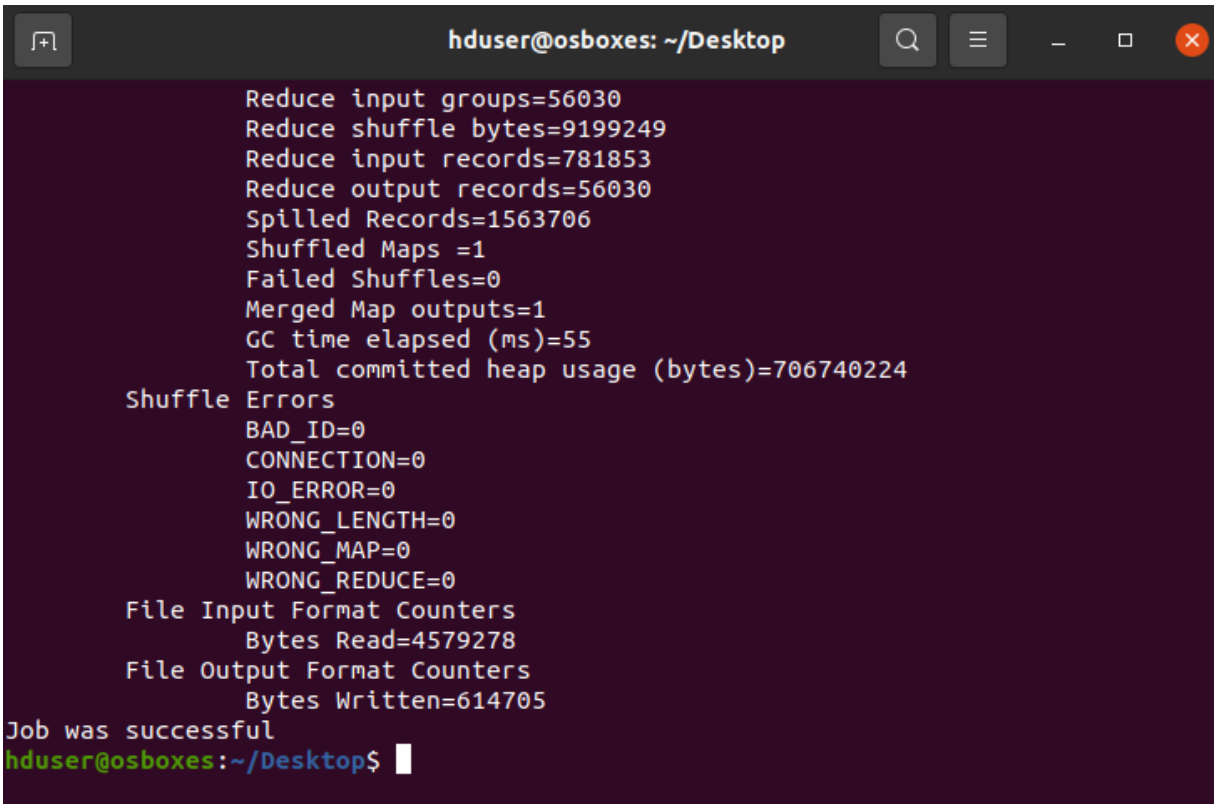


Im angegebenen Output-Verzeichnis befinden sich dann 2 Dateien, eine leere Datei "_SUCCESS" und eine Datei mit dem Ergebnis des Jobs.

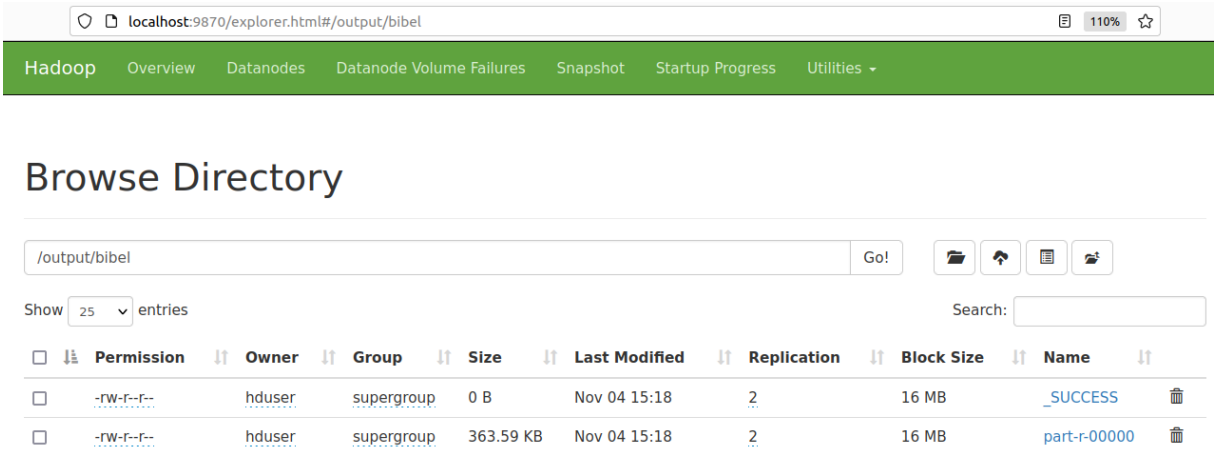

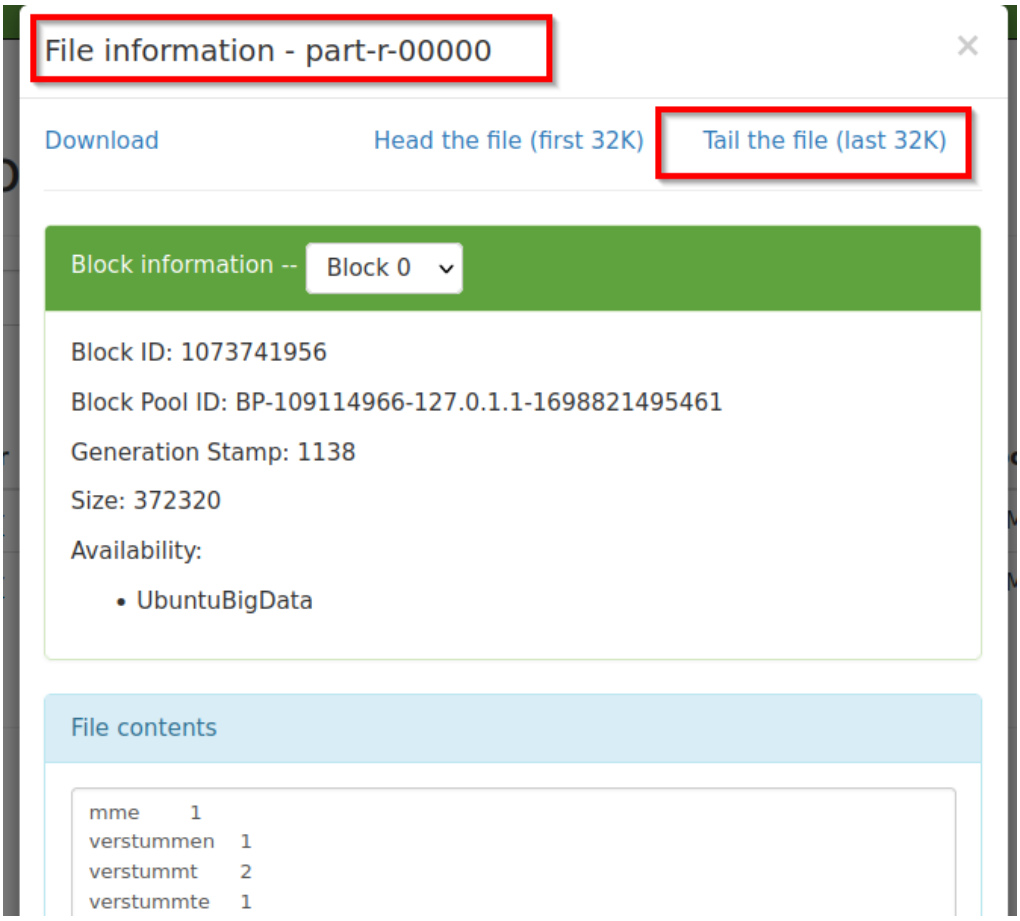


Wichtig: wenn der Job erneut gestartet werden soll, muss zuvor das Output-Verzeichnis gelöscht werden (sowohl wenn man Output ins lokale Dateisystem als auch wenn man dies in hdfs schreibt)!